

JULIEN RABAULT

AI Engineer | ML Engineer

+33 7 81 16 46 29
julienrabault@icloud.com
linkedin.com/in/julienrabault
github.com/JulienRabault
Toulouse, France

Conception et deploiement de systemes IA en production : plateformes agentiques (LangGraph, RAG, MCP), modeles deep learning (PyTorch, multi-GPU, supercalculateur Jean Zay), et pipelines MLOps. 4 ans au CNRS avec librairies en prod chez Meteo France et 2 publications peer-reviewed. Aujourd'hui chez Berger-Levrault : Athena, plateforme agentique multi-agents deployee pour tous les clients du groupe. Base a Toulouse, mobile Paris / Montreal.

COMPETENCES TECHNIQUES

Agentique & RAG : RAG / GraphRAG, Multi-agents, MCP Protocol, LangChain / LangGraph, Prompt Engineering, Structured Outputs, Embeddings, LLM Routing, Fine-tuning

Deep Learning : PyTorch, Transformers, Computer Vision, Diffusion Models (DDPM), NLP, CNNs / U-Net / YOLOv5, Modeles generatifs (GAN, VAE)

MLOps & Infra : Docker, AWS, CI/CD, MLFlow, Airflow, Kubernetes, Celery, Langfuse, HPC / Slurm, Linux

Developpement : Python, FastAPI, HuggingFace, Qdrant / pgvector, Mistral / OpenAI API, Git, SOLID / Architecture, C#, SQL

EXPERIENCES PROFESSIONNELLES

AI ENGINEER

Fevr. 2026 - present

Berger-Levrault | Toulouse | Equipe R&D IA, 12 personnes

Conception et developpement d'**Athena**, plateforme agentique de Berger-Levrault : multi-agents, routage intelligent, connexion aux documents et APIs metier pour tous les clients (collectivites, industrie, maintenance). Deploiement en cours, ~30 utilisateurs pilotes.

Architecture multi-agents

Conception de l'architecture LangGraph, routage par type de question, orchestration agents RAG + agents MCP, integration du sourcing des reponses. **Plateforme en production.**

Content-extractor - OCR/PDF/DOCX

Refonte complete du service d'extraction : OCR, images, PDF, DOCX. Batch async (Celery + API batch Mistral), architecture factory/registry. **-50% sur les couts d'extraction.**

Pipelines Airflow

Reprise et evolution des pipelines d'ingestion documentaire (PDF, notices, work orders). **5 DAGs operationnels** (1 par client).

MCP Builder

Un LLM analyse les specs OpenAPI (regroupement, masquage, descriptions), revue human-in-the-loop. **120+ APIs internes cartographiees.**

MACHINE LEARNING ENGINEER

Dec. 2021 - Janv. 2026

CNRS - Programme National de Recherche en IA (PNRIA) | Toulouse

Accompagnement d'equipes de recherche en France. 2 projets en parallele (6-12 mois), livres a Meteo France, CNES, CEA, INEE. Entrainement et fine-tuning sur Jean Zay (multi-GPU DDP, 8 GPUs, Slurm). Profilage PyTorch.

GENS / MetScore - Meteo France

Fine-tuning DDPM en PyTorch, optimisation multi-GPU. Conception de MetScore (config YAML, librairie Python). **Librairie en prod** + POC diffusion **-20% calcul.** Co-auteur papier AMS 2025.

DeepFaune - CNRS/INEE

Fine-tuning YOLOv5 sur 1,5M images (24 classes), multi-GPU, desequilibre de classes. **93% accuracy, 3x plus rapide.** Publication peer-reviewed.

Autres contributions

AUTOFILL (CEA, PairVAE, generation de donnees nanomatériaux, MAE 0,98), BIGSF (CNES, tech lead et refacto d'architecture, librairie d'analyse d'images de filaments galactiques), MORPHOGAN (Univ. Lorraine, refonte code StyleGAN2, pipeline automatisee). Formation *Introduction aux LLMs* (3h, ~25 doctorants/chercheurs CNRS).

INGENIEUR LOGICIEL (alternance)

Aout 2020 - Sept. 2021

Agile Automation | Montauban

Framework de supervision de machines robotisees (semi-conducteurs). C#, architecture OO, IHM, CI/CD. Equipe de 5 ingenieurs, Agile/Scrum.

FORMATIONS

MASTER - IA ET RECONNAISSANCE DES FORMES (IARF)

2019 - 2021

Universite Paul Sabatier Toulouse III - IRIT | Deep Learning, Vision, NLP

LICENCE INFORMATIQUE

2016 - 2019

Universite Paul Sabatier Toulouse III

Langues : Francais (natif) | Anglais courant (B2)

PUBLICATIONS

"Enriching Operational High-Resolution Ensemble Forecasts with StyleGAN-2" - AIES, 2025. **3e auteur**, peer-reviewed.

"The DeepFaune initiative: automatic identification of European fauna" - **Julien Rabault** et al. **Co-auteur**, peer-reviewed.

PROJETS OPEN SOURCE

LLMock (PyPI) - Mock server LLM, retries/fallbacks, 10+ providers, OpenAI-compatible. Python, FastAPI.

DDPM-weather - Modele de diffusion pour debruitage d'images meteo, -20% ressources. PyTorch, Meteo France.

uniqpath (PyPI) - Generateur de chemins uniques : suffixes incrementaux, UUID, timestamps.

BananaML - Pipeline ML end-to-end sur AWS. Computer Vision + API REST. FastAPI, Docker, CI/CD.