JULIEN RABAULT

Ingénieur IA, agents LLM et RAG en production

Toulouse, ouvert à Paris, remote, Canada
+33 7 81 16 46 29 julienrabault@icloud.com
linkedin.com/in/julienrabault
github.com/JulienRabault
julienrabault.github.io

Conception de harnais agentiques et mise en production d'agents LLM et de systèmes RAG chez des clients, après quatre ans de deep learning sur supercalculateur au CNRS (PyTorch, multi-GPU). Deux publications peer-reviewed.

COMPÉTENCES

Systèmes agentiques : Harnais d'agents (boucle agentique, tool calling, middlewares, mémoire, human-in-the-loop), LangChain / LangGraph / Deep Agents, RAG, MCP, evals (golden sets, LLM-as-judge, A/B testing), multimodal (OCR, vision, audio), fine-tuning

Langages & données : Python, PyTorch, FastAPI, SQL, Weaviate, PostgreSQL, MongoDB, Hugging Face, API Mistral et OpenAI

Infrastructure : Docker, GitLab CI, AWS, Celery, RabbitMQ, Airflow, Langfuse, Slurm, Linux

EXPÉRIENCE PROFESSIONNELLE

AI Engineer, Berger-Levrault, Toulouse (équipe R&D IA)

Janv. 2026 - présent

Athena, plateforme agentique branchée sur les documents et APIs métier de ses clients (collectivités, juridique, industrie, RH publique) : 100k documents, pilote de 6 mois avec 70 utilisateurs, mise en production en cours. Besoins recueillis auprès des business units, ateliers clients.

Cœur de la plateforme

- **Harnais agentique** (LangChain / LangGraph), architecture conçue et portée. Passage d'un routeur d'agents à une boucle agentique configurée par profil, étendue par middlewares : mémoire persistante, validation humaine des actions sensibles, gestion du contexte (résumé, budget de tokens), garde-fous, skills, sous-agents. Prompt caching partagé entre conversations, tenants et clients : -40 à -50 % de coûts d'inférence (estimé). Migration en cours vers Deep Agents.
- **Outils de l'agent** : RAG agentique, recherche web, calcul et serveurs MCP, sur la même boucle, sans graphe par outil.
- **Évaluation et monitoring** : refonte du monitoring sous Langfuse v4 (traces, datasets, évaluations et scoring automatiques, LLM-as-judge), golden sets, comparaison de modèles, de prompts et d'architectures, suivi des régressions et des coûts ; cloisonnement des contenus récupérés contre l'injection de prompt indirecte.
- **MCP Builder** : transforme les APIs métier internes en serveurs MCP. Un LLM sélectionne les endpoints utiles, audite leurs lacunes et génère des tools sur mesure (workflows ou code Python via FastMCP), en human-in-the-loop.

Services et pipelines LLM

- **Content-extractor**, extraction multimodale (OCR / PDF / DOCX / audio) : service FastAPI créé de zéro, 7 pipelines, batch asynchrone (Celery + API batch Mistral), architecture factory/registry. Déployé, -50 % sur les coûts d'extraction.
- **Agent de templates** : extrait des templates de documents Word, qu'un second agent remplit en langage naturel. En production.
- **Structuration de données métier** (RH publique) : comptes rendus d'entretiens transformés en besoins normalisés, dédoublonnés, rapprochés d'un catalogue. Ingestion RAG enrichie (Airflow) : chunking, embeddings, questions indexées.

Machine Learning Engineer, CNRS (PNRIA), Toulouse

Déc. 2021 - Janv. 2026 (4 ans)

Ingénieur intégré aux équipes de recherche (météo, astrophysique, matériaux, éthologie, biologie) : plus de 10 projets de 6 à 12 mois, 2 en parallèle, du recueil du besoin à la livraison, pour Météo France, CNES, CEA, INEE. Entraînement et fine-tuning sur le supercalculateur Jean Zay (multi-GPU DDP, Slurm). Formation d'introduction aux LLMs pour 25 doctorants.

Sélection de projets

- **GENS / MetScore, Météo France :** entraînement multi-GPU et fine-tuning d'un modèle de diffusion (DDPM) en PyTorch ; conception de MetScore (métriques), toujours en production. POC : -20 % de calcul, qualité équivalente. Co-auteur, AIES 2025.
- **DeepFaune, CNRS / INEE :** fine-tuning YOLOv8 sur 1,5 M d'images (24 classes), gestion du déséquilibre de classes. 93 % de précision, inférence 3 fois plus rapide. Publication peer-reviewed.
- **BIGSF, CNES :** tech lead sur la refonte d'une librairie U-Net d'analyse d'images galactiques, toolbox publique.
- **AUTOFILL, CEA :** PairVAE pour la complétion de données de nanomatériaux (MAE 0,98). **MORPHOGAN, Univ. Lorraine :** refonte d'un code StyleGAN2, pipeline automatisée et conteneurisée.

Ingénieur logiciel, Agileo Automation, Montauban

Août 2020 - Sept. 2021 (1 an)

- **Framework de supervision de machines de production** (semi-conducteurs) : C#, IHM, CI/CD, équipe de 5 en Scrum.

FORMATION

Master intelligence artificielle et reconnaissance des formes, Université Paul Sabatier / IRIT (2021) ; **Licence informatique**, Université Paul Sabatier (2019)

PUBLICATIONS & OPEN SOURCE

Enriching Operational High-Resolution Ensemble Forecasts with StyleGAN-2, AIES 2025, peer-reviewed.

The DeepFaune initiative: automatic identification of European fauna, peer-reviewed.

LangChain : contribution mergée (intégration Mistral) ; **LLMock** (PyPI) : serveur de mock LLM, 10+ fournisseurs ; **DDPM-weather** : diffusion pour images météo.