

JULIEN RABAULT

Ingénieur IA · agents LLM & RAG en production

📍 Toulouse, France 📞 +33 7 81 16 46 29

✉️ julienrabault@icloud.com

🌐 linkedin.com/in/julienrabault

🐙 github.com/JulienRabault

🌐 julienrabault.github.io

Conception et mise en production d'agents LLM et de systèmes RAG chez des clients, après quatre ans de recherche appliquée au CNRS : entraînement et fine-tuning de modèles deep learning sur supercalculateur (PyTorch, multi-GPU). Deux publications peer-reviewed.

COMPÉTENCES

Systèmes agencés : Agents LLM en production, RAG, evals (golden sets, LLM-as-judge), observabilité, sécurité des agents, suivi des coûts d'inférence, multimodal (OCR, vision, audio), MCP, LangChain / LangGraph, fine-tuning

Langages & données : Python, FastAPI, SQL, Weaviate, PostgreSQL, MongoDB, Hugging Face, API Mistral et OpenAI

Infrastructure : Docker, Kubernetes, Helm, GitLab CI, AWS, Celery, RabbitMQ, S3, Airflow, MLflow, Langfuse, Slurm, Linux

Machine learning : PyTorch, Transformers, entraînement multi-GPU (DDP), modèles de diffusion, computer vision, U-Net, YOLO, GAN, VAE

EXPÉRIENCE PROFESSIONNELLE

AI Engineer, Berger-Levrault — Toulouse · Équipe R&D IA

Janv. 2026 – présent

Conception et développement d'Athena, la plateforme agentique de Berger-Levrault : agents branchés sur les corpus documentaires et les APIs métier des clients du groupe (collectivités, juridique, industrie, maintenance, RH publique). Corpus de ~100k documents techniques, ~70 utilisateurs pilotes, observabilité, monitoring et suivi des coûts (Langfuse), ateliers clients.

- **Architecture agentique d'Athena** (LangGraph), refonte en équipe : passage d'un routeur (un agent par tâche : RAG, APIs MCP, rapports) à un agent réutilisable configuré par profil, avec gestion du contexte, skills générés automatiquement, orchestration de sous-agents et contrat d'événements unifié. Ajouter un outil ne demande plus de construire un graphe.
- **Évaluation et fiabilité des agents** : jeux de référence (golden sets), scoring LLM-as-judge, bancs comparatifs entre architectures et suivi des régressions via Langfuse.
- **Sécurité des agents** : cloisonnement des contenus récupérés (injection de prompt indirecte), bornes d'exécution des tools (timeouts, restriction par profil d'agent).
- **MCP Builder** : transforme les APIs des BU en serveurs MCP. Un LLM sélectionne les endpoints utiles, audite leurs lacunes et génère des tools sur mesure (workflows ou code Python via FastMCP), en human-in-the-loop. Créé seul, déployé. Modèle retenu sur benchmark : 4,1× plus rapide et 3,2× moins cher.
- **Content-extractor**, extraction multimodale (OCR / PDF / DOCX / audio) : service créé de zéro, 7 pipelines d'extraction, traitement batch asynchrone (Celery + API batch Mistral), architecture factory/registry extensible. Déployé, -50 % sur les coûts d'extraction.
- **Agent de templates de documents** : tools de lecture de documents Word pour en extraire des templates, puis second agent et tools permettant de remplir ces templates en langage naturel. Du prototype à la production.
- **Pipeline LLM de structuration de données métier** (RH du secteur public) : transforme des comptes rendus d'entretiens en besoins de formation normalisés, dédoublonnés et regroupés, puis rapprochés d'un catalogue.
- **Chaîne d'ingestion RAG** (Airflow) : étapes d'enrichissement ajoutées (data augmentation, chunking, embeddings, questions et mots-clés indexés, filtres temporels). Un DAG par client en production.

Machine Learning Engineer, CNRS · PNRIA — Toulouse

Déc. 2021 – Janv. 2026 · 4 ans

Réseau d'ingénieurs IA en appui aux équipes de recherche (météo, astrophysique, matériaux, éthologie, biologie). Plus de 10 projets accompagnés, jusqu'à 2 en parallèle (6-12 mois), pour Météo France, CNES, CEA, INEE. Entraînement et fine-tuning sur Jean Zay (multi-GPU DDP, 8 GPU, Slurm).

- **GENS / MetScore, Météo France** : optimisation multi-GPU et fine-tuning d'un modèle de diffusion (DDPM) en PyTorch ; conception de MetScore (bibliothèque de métriques), toujours en production. POC diffusion à -20 % de calcul à qualité équivalente. Co-auteur du papier AIES 2025.
- **DeepFaune, CNRS / INEE** : fine-tuning YOLOv8 sur 1,5 M d'images (24 classes), gestion du déséquilibre de classes. 93 % de précision, inférence 3× plus rapide. Publication peer-reviewed.

- **BIGSF, CNES** : tech lead sur la refonte d'une librairie d'analyse d'images de filaments galactiques (U-Net) : architecture modulaire, tests, documentation. Toolbox publique.
- **AUTOFILL, CEA** : implémentation du modèle PairVAE pour la génération et la complétion de données de nanomatériaux, erreur moyenne absolue de 0,98. Librairie paramétrable pour d'autres matériaux.
- **MORPHOGAN, Univ. Lorraine** : refonte complète d'un code StyleGAN2 pour l'étude de la variabilité morphologique d'ailes de papillons : pipeline automatisée, tests, conteneurisation.
- **Formation** : « Introduction aux LLMs » créée et dispensée à ~25 doctorants et chercheurs.

Ingénieur logiciel, Agileo Automation — Montauban

Août 2020 – Sept. 2021 · 1 an

- **Framework de supervision de machines robotisées** (semi-conducteurs) : C#, architecture orientée objets, IHM, CI/CD. Équipe de 5, Agile / Scrum.

FORMATION

Master intelligence artificielle et reconnaissance des formes, Université Paul Sabatier / IRIT 2019 – 2021

Licence informatique, Université Paul Sabatier Toulouse III 2016 – 2019

PUBLICATIONS

[Enriching Operational High-Resolution Ensemble Forecasts with StyleGAN-2](#), AIES 2025, peer-reviewed.

[The DeepFaune initiative: automatic identification of European fauna](#), peer-reviewed.

PROJETS OPEN SOURCE

LangChain : contribution mergée sur l'intégration Mistral, remontée des métadonnées de citation.

LLMock (PyPI) : serveur de mock LLM pour tester retries et fallbacks, plus de dix fournisseurs.

DDPM-weather : modèle de diffusion pour le débruitage d'images météorologiques.