

JULIEN RABAULT

Ingénieur IA · agents LLM & RAG en production

Toulouse, France ☎ +33 7 81 16 46 29

✉ julienrabault@icloud.com

in [linkedin.com/in/julienrabault](https://www.linkedin.com/in/julienrabault)

github.com/JulienRabault

Ⓜ julienrabault.github.io

Conception et mise en production d'agents LLM et de systèmes RAG chez des clients, après quatre ans de deep learning sur supercalculateur au CNRS (PyTorch, multi-GPU). Deux publications peer-reviewed.

COMPÉTENCES

Systèmes agencés : Agents LLM en production, RAG, evals (golden sets, LLM-as-judge), observabilité, sécurité des agents, multimodal (OCR, vision, audio), MCP, LangChain / LangGraph, fine-tuning

Langages & données : Python, PyTorch, FastAPI, SQL, Weaviate, PostgreSQL, MongoDB, Hugging Face, API Mistral et OpenAI

Infrastructure : Docker, Kubernetes, Helm, GitLab CI, AWS, Celery, RabbitMQ, Airflow, Langfuse, Slurm, Linux

EXPÉRIENCE PROFESSIONNELLE

AI Engineer, Berger-Levrault — Toulouse · Équipe R&D IA

Janv. 2026 – présent

Conception et développement d'Athena, la plateforme agencée de Berger-Levrault : agents branchés sur les corpus documentaires et les APIs métier des clients (collectivités, juridique, industrie, maintenance, RH publique). ~100k documents indexés, ~70 utilisateurs pilotes, observabilité et suivi des coûts sous Langfuse, ateliers clients.

- **Architecture agencée d'Athena** (LangChain / LangGraph), refonte en équipe : passage d'un routeur (un agent par tâche : RAG, APIs MCP, rapports) à un agent réutilisable configuré par profil, avec gestion du contexte, skills générés automatiquement, orchestration de sous-agents et contrat d'événements unifié. Ajouter un outil ne demande plus de construire un graphe.
- **Évaluation, fiabilité et sécurité des agents** : jeux de référence (golden sets), scoring LLM-as-judge, bancs comparatifs entre architectures et suivi des régressions via Langfuse ; cloisonnement des contenus récupérés contre l'injection de prompt indirecte et bornes d'exécution des tools.
- **MCP Builder** : transforme les APIs des BU en serveurs MCP. Un LLM sélectionne les endpoints utiles, audite leurs lacunes et génère des tools sur mesure (workflows ou code Python via FastMCP), en human-in-the-loop.
- **Content-extractor**, extraction multimodale (OCR / PDF / DOCX / audio) : service créé de zéro, 7 pipelines d'extraction, traitement batch asynchrone (Celery + API batch Mistral), architecture factory/registry extensible. Déployé, -50 % sur les coûts d'extraction.
- **Agent de templates de documents** : tools d'extraction de templates depuis des documents Word, puis second agent qui les remplit en langage naturel. Du prototype à la production.
- **Pipeline LLM de structuration de données métier** (RH du secteur public) : transforme des comptes rendus d'entretiens en besoins normalisés, dédoublonnés et rapprochés d'un catalogue. Également, enrichissement de la chaîne d'ingestion RAG (Airflow) : chunking, embeddings, questions et mots-clés indexés.

Machine Learning Engineer, CNRS · PNRIA — Toulouse

Déc. 2021 – Janv. 2026 · 4 ans

Réseau d'ingénieurs IA en appui aux équipes de recherche (météo, astrophysique, matériaux, éthologie, biologie). Plus de 10 projets accompagnés, jusqu'à 2 en parallèle (6-12 mois), pour Météo France, CNES, CEA, INEE. Entraînement et fine-tuning sur Jean Zay (multi-GPU DDP, 8 GPU, Slurm).

- **GENS / MetScore, Météo France** : optimisation multi-GPU et fine-tuning d'un modèle de diffusion (DDPM) en PyTorch ; conception de MetScore (bibliothèque de métriques), toujours en production. POC diffusion à -20 % de calcul à qualité équivalente. Co-auteur du papier AIES 2025.
- **DeepFaune, CNRS / INEE** : fine-tuning YOLOv8 sur 1,5 M d'images (24 classes), gestion du déséquilibre de classes. 93 % de précision, inférence 3x plus rapide. Publication peer-reviewed.
- **BIGSF (CNES), AUTOFILL (CEA), MORPHOGAN (Univ. Lorraine)** : tech lead sur la refonte d'une bibliothèque d'analyse d'images galactiques (U-Net, toolbox publique) ; PairVAE pour la complétion de données de nanomatériaux (MAE 0,98) ; refonte d'un code StyleGAN2. Formation « Introduction aux LLMs » dispensée à ~25 doctorants.

Ingénieur logiciel, Agileo Automation — Montauban

Août 2020 – Sept. 2021 · 1 an

- **Framework de supervision de machines de production** (semi-conducteurs) : C#, architecture orientée objets, IHM, CI/CD. Équipe de 5 en Scrum.

FORMATION

Master intelligence artificielle et reconnaissance des formes, Université Paul Sabatier / IRIT (2021) · Licence informatique, Université Paul Sabatier (2019)

PUBLICATIONS & OPEN SOURCE

Enriching Operational High-Resolution Ensemble Forecasts with StyleGAN-2, AIES 2025, peer-reviewed.

The DeepFaune initiative: automatic identification of European fauna, peer-reviewed.

LangChain : contribution mergée (intégration Mistral) · **LLMock** (PyPI) : serveur de mock LLM, 10+ fournisseurs ·

DDPM-weather : diffusion pour images météo.