

JULIEN RABAULT

AI Engineer | ML Engineer

+33 7 81 16 46 29
julienrabault@icloud.com
linkedin.com/in/julienrabault
github.com/JulienRabault
Toulouse, France
julienrabault.github.io

Conception et deploiement de systemes IA en production : plateformes agentiques (LangGraph, RAG, MCP), modeles deep learning (PyTorch, multi-GPU, supercalculateur Jean Zay), et pipelines MLOps. 4 ans au CNRS avec librairies en prod chez Meteo France et 2 publications peer-reviewed. Aujourd'hui chez Berger-Levrault : Athena, plateforme agentique multi-agents deployee pour tous les clients du groupe. Base a Toulouse, mobile Paris / Montreal.

COMPETENCES TECHNIQUES

Agentique & RAG :	RAG / GraphRAG, Multi-agents, MCP Protocol, LangChain / LangGraph, Prompt Engineering, Structured Outputs, Embeddings, LLM Routing, Fine-tuning
Deep Learning :	PyTorch, Transformers, Computer Vision, Diffusion Models (DDPM), NLP, CNNs / U-Net / YOLOv5, Modeles generatifs (GAN, VAE)
MLOps & Infra :	Docker, AWS, CI/CD, MLLow, Airflow, Kubernetes, Celery, Langfuse, HPC / Slurm, Linux
Developpement :	Python, FastAPI, HuggingFace, Qdrant / pgvector, Mistral / OpenAI API, Git, SOLID / Architecture, C#, SQL

EXPERIENCES PROFESSIONNELLES

AI ENGINEER Janv. 2026 - present
Berger-Levrault | Toulouse | Equipe R&D IA, 12 personnes

Conception et developpement d'Athena, plateforme agentique de Berger-Levrault : multi-agents, routage intelligent, connexion aux documents et APIs metier pour tous les clients (collectivites, industrie, maintenance). Deploiement en cours, ~30 utilisateurs pilotes.

Architecture multi-agents

Conception de l'architecture multi-agents (LangGraph), routage par type de question, orchestration d'agents RAG et d'agents sur APIs MCP, integration du sourcing des reponses. **Plateforme en production**, reponses sourcees et actionnables sur plusieurs domaines metier.

Content-extractor - OCR/PDF/DOCX

Refonte complete du service d'extraction : OCR, images, PDF, DOCX. Batch async (Celery + API batch Mistral), architecture factory/registry pour ajouter facilement de nouveaux formats. **-50% sur les couts d'extraction**.

Pipelines Airflow

Reprise et evolution en equipe des pipelines d'ingestion documentaire (PDF, notices, work orders, docs machine). **5 DAGs operationnels** (1 par client).

MCP Builder

Un LLM analyse les specs OpenAPI pour pre-traiter les endpoints (regroupement, masquage, generation de descriptions), puis revue human-in-the-loop pour valider routes, doc et connaissance metier. **120+ APIs internes cartographiees**, integration progressive au runtime.

MACHINE LEARNING ENGINEER Dec. 2021 - Janv. 2026
CNRS - Programme National de Recherche en IA (PNRIA) | Toulouse

Accompagnement d'equipes de recherche en France. 2 projets en parallele (6-12 mois), livres a Meteo France, CNES, CEA, INEE. Entrainement et fine-tuning sur Jean Zay (multi-GPU DDP, 8 GPUs, Slurm). Profilage PyTorch.

GENS / MetScore - Meteo France

Evaluation de modeles meteo en production, optimisation multi-GPU et fine-tuning d'un modele de diffusion (DDPM) en PyTorch sur Jean Zay. Conception de MetScore (configuration YAML, librairie Python). **Librairie toujours en prod** + POC diffusion a **-20% de calcul** a qualite equivalente. Co-auteur du papier AMS 2025.

DeepFaune - CNRS/INEE

Fine-tuning YOLOv5 sur dataset custom (1,5M images, 24 classes), entrainement multi-GPU, gestion du desequilibre de classes, optimisation precision/vitesse CPU. **93% sur 24 especes, 3x plus rapide**. Publication peer-reviewed.

Autres contributions

AUTOFILL (CEA, PairVAE, generation de donnees nanomatériaux, MAE 0,98), BIGSF (CNES, tech lead et refacto d'architecture, librairie d'analyse d'images de filaments galactiques), MORPHOGAN (Univ. Lorraine, refonte code StyleGAN2, pipeline automatisee). Formation *Introduction aux LLMs* (3h, ~25 doctorants/chercheurs CNRS).

INGENIEUR LOGICIEL (alternance) Aout 2020 - Sept. 2021
Agileo Automation | Montauban

Framework de supervision de machines robotisees (semi-conducteurs). C#, architecture OO, IHM, CI/CD. Equipe de 5 ingenieurs, Agile/Scrum.

FORMATIONS

MASTER - IA ET RECONNAISSANCE DES FORMES (IARF) 2019 - 2021
Universite Paul Sabatier Toulouse III - IRIT | Deep Learning, Vision, NLP

LICENCE INFORMATIQUE 2016 - 2019
Universite Paul Sabatier Toulouse III

Langues : Francais (natif) | Anglais courant (B2)

PUBLICATIONS

"Enriching Operational High-Resolution Ensemble Forecasts with StyleGAN-2" - AIES, 2025. **3e auteur**, peer-reviewed.
"The DeepFaune initiative: automatic identification of European fauna" - **Julien Rabault** et al. **Co-auteur**, peer-reviewed.

PROJETS OPEN SOURCE

LLMock (PyPI) - Mock server LLM, retries/fallbacks, 10+ providers, OpenAI-compatible. Python, FastAPI.
DDPM-weather - Modele de diffusion pour debruitage d'images meteo, -20% ressources. PyTorch, Meteo France.
unipath (PyPI) - Generateur de chemins uniques : suffixes incrementaux, UUID, timestamps.
BananaML - Pipeline ML end-to-end sur AWS. Computer Vision + API REST. FastAPI, Docker, CI/CD.