

JULIEN RABAUT

Applied AI / ML Engineer

Toulouse, France +33 7 81 16 46 29

julienrabault@icloud.com

[linkedin.com/in/julienrabault](https://www.linkedin.com/in/julienrabault)

github.com/JulienRabault

julienrabault.github.io

Ingénieur IA appliquée. 4 ans au CNRS à entraîner et industrialiser des modèles deep learning en production (PyTorch, multi-GPU, supercalculateur Jean Zay), 2 publications peer-reviewed. Aujourd'hui chez Berger-Levrault : conception d'Athena, plateforme agentique multi-agents (LangGraph, RAG, MCP) déployée chez des clients.

COMPÉTENCES TECHNIQUES

Agentique & RAG	RAG / GraphRAG, agents tool-first, multi-agents, sous-agents, MCP, LangChain / LangGraph, prompt engineering, structured outputs, embeddings, fine-tuning
Deep Learning	PyTorch, Transformers, computer vision, modèles de diffusion (DDPM / DDIM), NLP, CNN / U-Net / YOLOv8, modèles génératifs (GAN, VAE)
MLOps & Infra	Docker, AWS, CI/CD, MLflow, Airflow, Kubernetes, Celery, Langfuse, HPC / Slurm, Linux
Développement	Python, FastAPI, Hugging Face, Weaviate, API Mistral / OpenAI, Git, SOLID / architecture, C#, SQL

EXPÉRIENCE PROFESSIONNELLE

AI Engineer

Janv. 2026 - présent

Berger-Levrault · Toulouse · Équipe R&D IA

Conception et développement d'Athena, la plateforme agentique de Berger-Levrault : agents connectés aux documents et aux APIs métier pour les clients du groupe (collectivités, santé, industrie, maintenance). ~70 utilisateurs pilotes, observabilité Langfuse.

- Refonte de l'architecture agentique d'Athena (plateforme multi-agents en production, LangGraph), en équipe : passage d'un routeur (un agent par tâche : RAG, APIs MCP, rapports) à un agent unique tool-first, avec gestion du contexte, skills et création automatique de skills, et orchestration de sous-agents.
- Content-extractor (OCR / PDF / DOCX) : refonte complète, traitement batch asynchrone (Celery + API batch Mistral), architecture factory/registry extensible. Déployé, -50 % sur les coûts d'extraction.
- MCP Builder : transforme les APIs des BU en serveurs MCP. Un LLM sélectionne les endpoints utiles, audite leurs lacunes et génère des tools sur mesure (workflows ou code Python via FastMCP), en human-in-the-loop. Déployé.
- Chaîne d'ingestion RAG (Airflow). Complétion et ajout d'étapes d'enrichissement : data augmentation, chunking, embeddings, génération de questions/mots-clés indexés, filtres temporels.
- Évaluation et fiabilité des agents : jeux de référence (golden sets), scoring LLM-as-judge et suivi des régressions via Langfuse.

Machine Learning Engineer

Déc. 2021 - Janv. 2026 · 4 ans

CNRS · Programme National de Recherche en IA (PNRIA) · Toulouse

Réseau d'ingénieurs IA en appui aux équipes de recherche (météo, astrophysique, matériaux, éthologie, biologie). Plus de 10 projets accompagnés, jusqu'à 2 en parallèle (6-12 mois), pour Météo France, CNES, CEA, INEE. Entraînement et fine-tuning sur Jean Zay (multi-GPU DDP, 8 GPU, Slurm).

- GENS / MetScore, Météo France** : optimisation multi-GPU et fine-tuning d'un modèle de diffusion (DDPM) en PyTorch ; conception de MetScore (bibliothèque de métriques), toujours en production. POC diffusion à -20 % de calcul à qualité équivalente. Co-auteur du papier AMS 2025.
- DeepFaune, CNRS / INEE** : fine-tuning YOLOv8 sur 1,5 M d'images (24 classes), gestion du déséquilibre de classes. 93 % de précision, inférence 3x plus rapide. Publication peer-reviewed.
- BIGSF, CNES** : tech lead sur la refonte d'une bibliothèque d'analyse d'images de filaments galactiques (U-Net) : architecture modulaire, tests, documentation. Toolbox publique.
- Autres** : AUTOFILL (CEA, PairVAE, MAE 0,98), MORPHOGAN (StyleGAN2, Univ. Lorraine). Formation « Introduction aux LLMs » (3 h, ~25 doctorants / chercheurs).

Ingénieur logiciel (alternance)

Août 2020 - Sept. 2021 · 1 an

Agileo Automation · Montauban

Framework de supervision de machines robotisées (semi-conducteurs) : C#, architecture orientée objets, IHM, CI/CD. Équipe de 5, Agile / Scrum.

FORMATION

Master IA et Reconnaissance des Formes (IARF), Université Paul Sabatier Toulouse III / IRT	2019 - 2021
Licence Informatique, Université Paul Sabatier Toulouse III	2016 - 2019
Langues : Français (natif) · Anglais professionnel (rédaction scientifique, documentation technique)	

PUBLICATIONS

Enriching Operational High-Resolution Ensemble Forecasts with StyleGAN-2. AIES, 2025. 3e auteur, peer-reviewed.
The DeepFaune initiative: automatic identification of European fauna. N. Rigoudy et al. Co-auteur, peer-reviewed.

PROJETS OPEN SOURCE

LLMock (PyPI). Mock server LLM : retries / fallbacks, 10+ providers, compatible OpenAI. Python, FastAPI.
DDPM-weather. Modèle de diffusion pour le débruitage d'images météo, -20 % de ressources. PyTorch.
BananaML. Pipeline ML end-to-end sur AWS : computer vision + API REST. FastAPI, Docker, CI/CD.